hw7.md 2024-06-03

Homework7

1. MapReduce模型采用Master(Job Tracker)-Slave (Task Tracker)结构, 试述Job Tracker和Task Tracker的 功能。

- 2. 试述MapReduce工作流程。
- 3. 提供MapReduce运行成功的截图。

Q1

MapReduce模型采用Master-Slave架构,其中Master节点称为JobTracker,Slave节点称为TaskTracker。

JobTracker (主节点)

1. 作业管理:

- 作业调度:负责接收来自客户端的作业(job)请求·拆分为多个任务(task)并分配给各个 TaskTracker执行。
- o 资源分配:根据集群中各个TaskTracker的资源情况,合理分配任务,确保资源的有效利用。

2. 仟务监控:

- **任务追踪**:实时监控每个TaskTracker上任务的执行情况,记录任务的状态和进度。
- **失败处理**:当检测到某个任务失败时,重新调度该任务到其他TaskTracker上执行,确保作业能够成功完成。

3. 负载均衡:

数据本地性优化:尽量将任务分配到数据所在的节点上,以减少数据传输,提高执行效率。

4. 系统管理:

- 健康检查:定期检查TaskTracker的健康状态,确保集群的稳定运行。
- **日志记录**:记录作业执行的详细日志,便于故障排查和系统调优。

TaskTracker(从节点)

1. 任务执行:

- **任务接收**:从JobTracker接收任务,并在本地执行这些任务(包括Map任务和Reduce任务)。
- **任务报告**:定期向JobTracker报告任务的执行状态和进度。

2. 资源管理:

○ 资源监控: 监控本地资源的使用情况,如CPU、内存、磁盘等,确保任务能够顺利执行。

hw7.md 2024-06-03

○ 任务分配:根据本地资源情况,合理分配任务执行的资源。

3. 任务管理:

- 任务重启:在任务执行失败时,尝试重新执行任务,确保任务能够完成。
- 中间数据存储:在本地存储Map任务的输出结果(中间数据),供Reduce任务使用。

4. 故障处理:

- 任务失败报告: 当任务执行失败时·及时向JobTracker报告·便于JobTracker进行重新调度。
- o 节点故障报告: 当节点发生故障时, 及时通知JobTracker, 以便系统进行故障恢复。

Q2

1. 作业提交 (Job Submission)

客户端提交一个MapReduce作业(job)给JobTracker。这个作业包括输入数据的位置、Map和Reduce函数的定义、输出数据的位置和配置参数。

2. 作业初始化 (Job Initialization)

JobTracker接收到作业请求后,将作业划分成多个任务(tasks),包括Map任务和Reduce任务。JobTracker还会为每个任务分配一个唯一的任务ID,并创建作业的运行环境。

3. Map任务执行(Map Task Execution)

1. 任务分配:

JobTracker将Map任务分配给各个TaskTracker。优先将任务分配给存储输入数据的节点,以减少数据传输。

2. 数据读取:

• TaskTracker读取本地文件系统或HDFS中的输入数据。

3. 执行**Map**函数:

TaskTracker对读取到的数据块执行用户定义的Map函数,将输入数据转换为键值对(key-value pairs)。

4. 中间数据存储:

Map任务生成的中间数据会被临时存储在本地磁盘上,并进行分区,每个分区对应一个Reduce任务。

4. Shuffle和Sort (Shuffle and Sort)

1. Shuffle:

Map任务完成后·TaskTracker将中间数据根据键值对的键进行分区和排序·并将这些数据发送给相应的Reduce任务所在的TaskTracker。

2. **Sort**:

hw7.md 2024-06-03

o 每个Reduce任务在接收到来自不同Map任务的中间数据后,会对这些数据进行合并和排序。

5. Reduce任务执行(Reduce Task Execution)

1. 任务分配:

○ JobTracker将Reduce任务分配给TaskTracker。

2. 执行Reduce函数:

o TaskTracker对合并排序后的中间数据执行用户定义的Reduce函数,将中间结果汇总成最终结果。

3. 输出数据存储:

• Reduce任务的输出数据会被写入到HDFS或本地文件系统中。

6. 作业完成 (Job Completion)

1. 状态报告:

• TaskTracker定期向JobTracker报告任务的执行状态。

2. 作业完成通知:

• 当所有的Map和Reduce任务都成功完成后,JobTracker会通知客户端作业完成。

3. 清理工作:

○ JobTracker和TaskTracker清理作业运行过程中产生的临时数据和资源。

MapReduce通过将大规模数据处理任务分解为小任务,并行执行Map和Reduce函数,实现了高效的数据处理和分析。JobTracker负责任务的调度和监控,而TaskTracker负责具体任务的执行和状态报告,确保作业的顺利完成。

Q3

运行成功截图如下所示:

```
hadoop@dblab-VirtualBox:/usr/local/hadoop/bin$ ./hadoop fs -cat /output/part-r-0
0000
hadoop 2
hello 2
is 1
powerful 1
spark 1
```