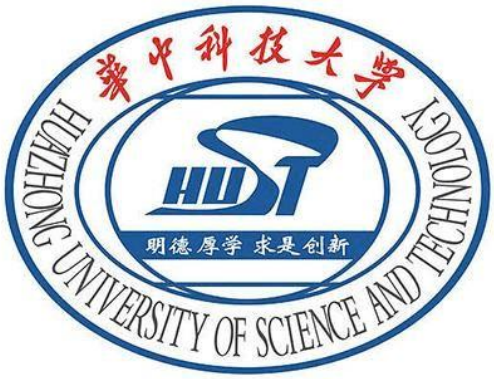

华中科技大学

HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY

数据挖掘实验报告

Apriori 频繁集挖掘

学　　院：电子信息与通信学院

班　　级：　　提高 2101 班

姓　　名：　　杨筠松

学　　号：　　U202115980

实验时间：　　2024 年 4 月

Apriori 算法是一种发掘事物内在关联关系的算法，它可以加快关联分析的速度，从而让我们更有效的进行关联分析。

1，关联分析

关联分析用于发掘大规模数据集中的内在关系。
关联分析一般要分析数据集中的**频繁项集**（frequent item sets）和**关联规则**（association rules）：

- 频繁项集：是数据集中**频繁项**的集合，集合中可以有**一项或多项**物品。
- 关联规则：暗示了两种物品之间可能存在很强的内在关系。

假设，我们收集了一家商店的交易清单：

交易编号	购物清单
1	牛奶，面包
2	牛奶，面包，火腿
3	面包，火腿，可乐
4	火腿，可乐，方便面
5	面包，火腿，可乐，方便面

频繁项集是一些经常出现在一起的物品集合。比如：`{牛奶，面包}`，`{火腿，方便面，可乐}`都是频繁项集的例子。关联规则意味着有人买了一种物品，还会买另一种物品。比如`方便面->火腿`，就是一种关联规则，表示如果买了方便面，还会买火腿。

2，三个重要概念

关联分析中有三个重要的概念，分别是：

- 支持度
- 可信度 / 置信度
- 提升度

支持度
要进行关联分析，首先要寻找**频繁项**，也就是频繁出现的物品集。那么怎样才叫频繁呢？我们可以用**支持度**来衡量频繁。

支持度是针对**项集**来说的，一个项集的支持度就是该项集的记录占总记录的比例。通常可以定义一个**最小支持度**，从而只保留满足最小支持度的项集。

一个项集`{A}`的支持度的定义如下：

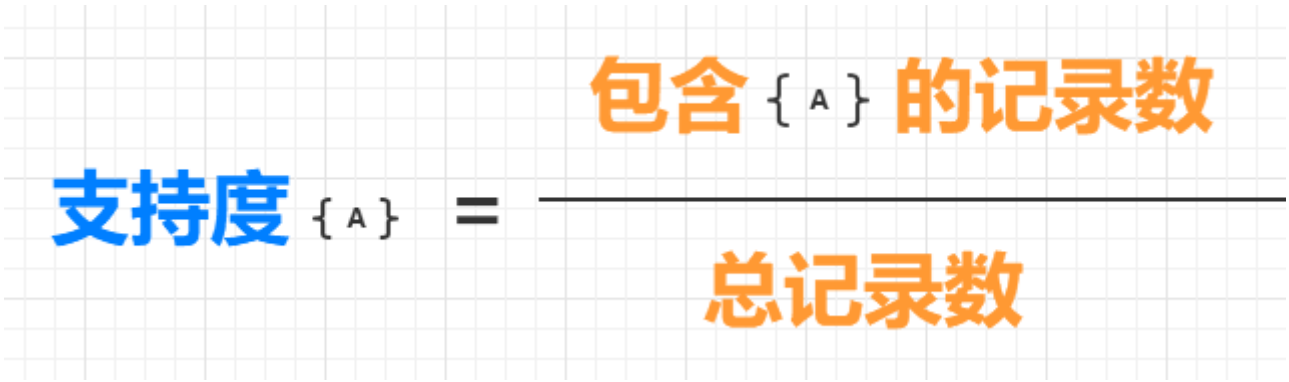

比如，在上面表格中的 5 项记录中，`{牛奶}`出现在了两条记录中，所以`{牛奶}`的支持度为`2/5`；而`{面包，火腿}`出现在了三条记录中，所以`{面包，火腿}`的支持度为`3/5`。

可信度

可信度又叫**置信度**，它是针对**关联规则**来说的，比如`{火腿}->{可乐}`。

一个关联规则`{A}->{B}`表示，如果购买了**物品 A**，会有多大的概率购买**物品 B**？它的可信度的定义如下：

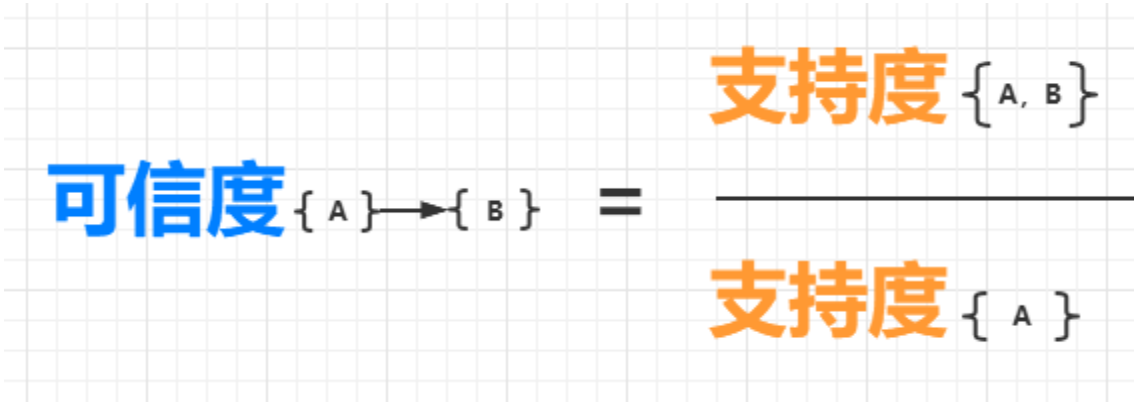

所以，在上面的表格中，`{火腿，可乐}`的支持度是`3/5`，`{火腿}`的支持度是`4/5`，所以`{可乐}->{火腿}`的可信度为`3/5`除以`4/5`，等于`0.75`。这意味着，如果购买了火腿，有`75%`的可能性会购买可乐。

提升度

提升度也是针对关联规则来说的，它表示的是“如果购买物品 A，会对购买物品 B 的概率**提升**多少”。

一个关联规则`{A}->{B}`的提升度的定义如下：

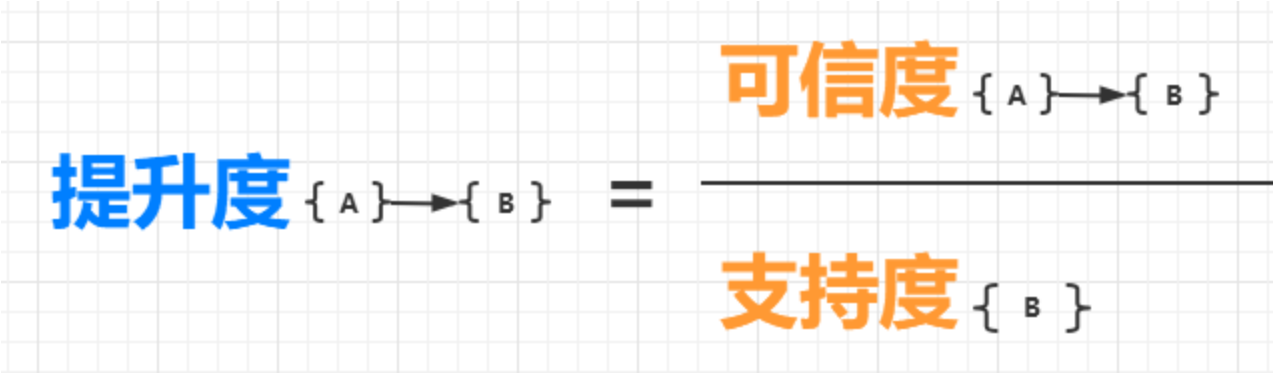

提升度会有三种情况：

- 提升度{A}->{B} > 1：表示购买物品 A 对购买物品 B 的概率有提升。
- 提升度{A}->{B} = 1：表示购买物品 A 对购买物品 B 的概率没有提升，也没有下降。
- 提升度{A}->{B} < 1：表示购买物品 A 对购买物品 B 的概率有下降。

3，如何寻找频繁项

寻找频繁项的一个简单粗暴的方法是，**对所有的物品进行排列组合**，然后计算所有组合的支持度，这种算法也可以叫做**穷举法**。

穷举法

穷举法就是列出所有物品的组合，然后计算每种组合的支持度。

比如，我们有一个物品集{0，1，2，3}，其中有四个物品，那么所有的物品组合如下：

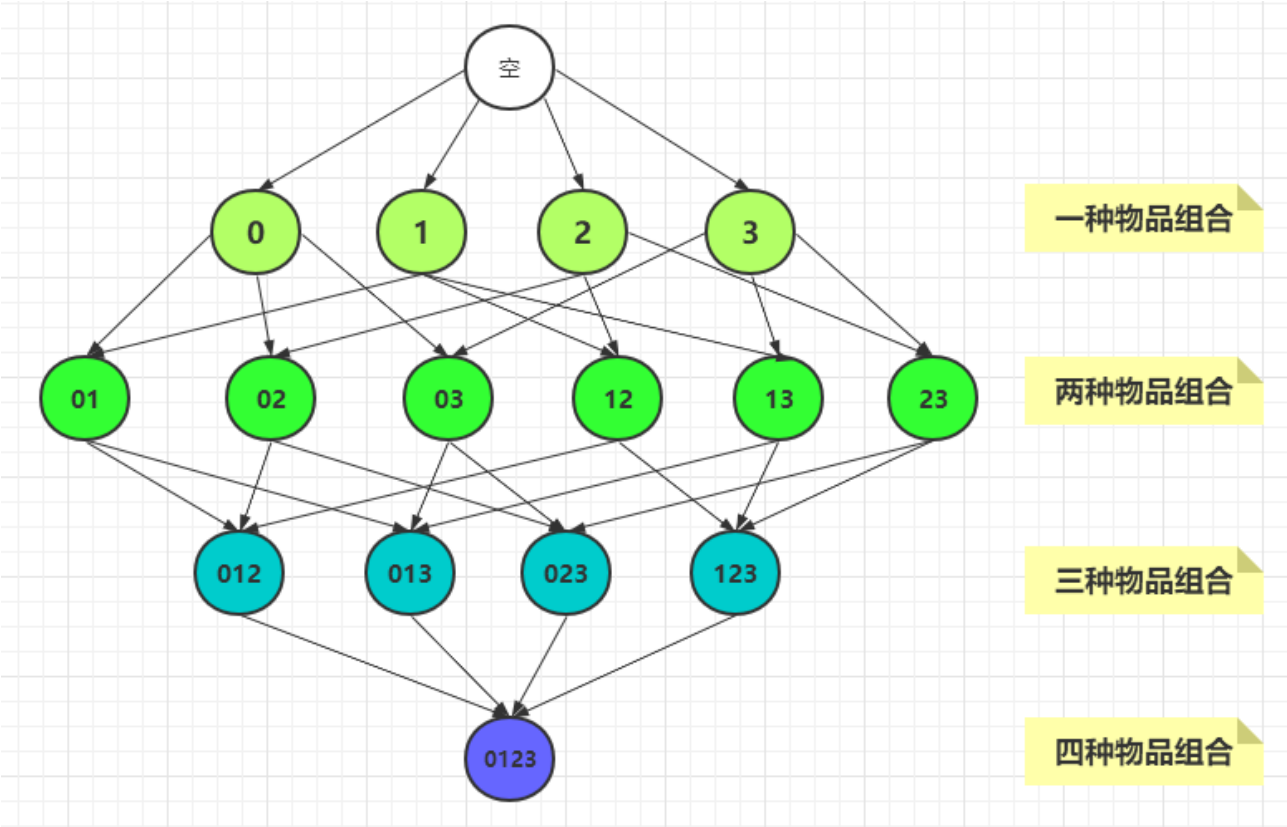

从图中可以看到一共有 **15** 种组合，计算每一种组合的支持度都需要遍历一遍所有的记录，检查每个记录中是否包含该组合。因此有多少种组合，就需要遍历多少遍记录，时间复杂度则会很大。
可以总结出：包含 **N** 种物品的数据集，共有 $2^N - 1$ 种组合。为了计算每种组合的支持度，则需要遍历 $2^N - 1$ 次记录。
如果一个商店中有 100 款商品，将会有 $1.26*10^{30}$ 种组合，这是一个非常庞大的数字。而普通商店一般都会有成千上万的商品，那么组合数将大到无法计算。

4，Apriori 算法

为了降低计算所需的时间，1994 年 **Agrawal** 提出了著名的 **Apriori 算法**，该算法可以有效减少需要计算的组合的数量，避免组合数量的指数增长，从而在合理的时间内计算出频繁项集。
Apriori 原理是说：如果一个项集是**非频繁集**，那么它的所有超集也是**非频繁的。**
比如下图中的项集`{1, 3}`是非频繁集，那么`{0, 1, 3}`，`{1, 2, 3}`，`{0, 1, 2, 3}`就都是非频繁项集。这就大大减少了需要计算的项集的数量。

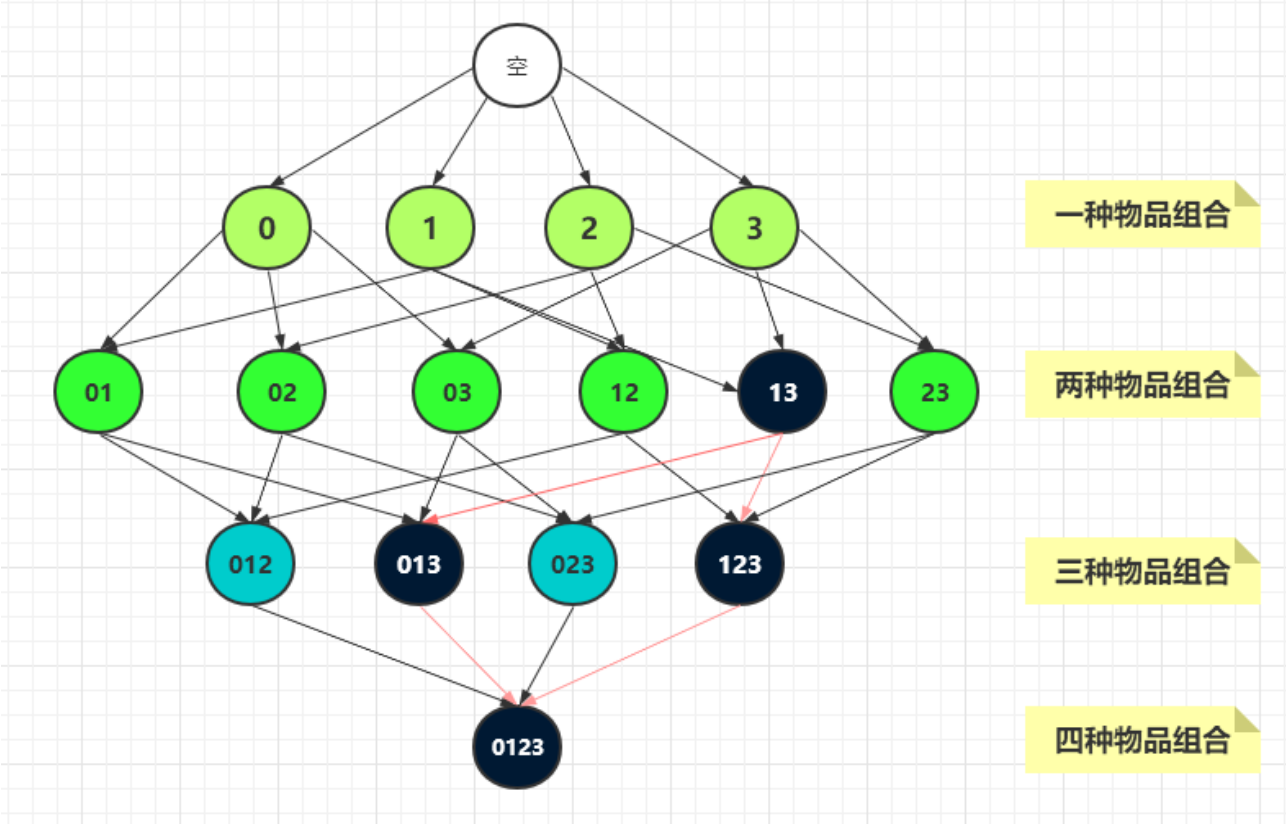

5，Apriori 算法的实现

交易编号	购物清单
1	牛奶，面包
2	牛奶，面包，火腿

交易编号	购物清单
3	面包，火腿，可乐
4	火腿，可乐，方便面
5	面包，火腿，可乐，方便面

这里，我们使用 **Apriori 算法**来寻找上文表格中的购物清单的频繁项集（为了方便查看，我把表格放在这里）。

efficient_apriori 模块

Efficient-Apriori 包是 **Apriori 算法**的稳定高效的实现，该模块适用于 `Python 3.6+`。

使用 **Apriori 算法**要先安装：`pip install efficient-apriori`

efficient_apriori 包中有一个 `apriori` 函数，原型如下（这里只列出了常用参数）：

```
apriori(data,
  min_support = 0.5,
  min_confidence = 0.5)
```

参数的含义：

- **data**：表示数据集，是一个列表。列表中的元素可以是元组，也可以是列表。
- **min_support**：表示最小支持度，小于最小支持度的项集将被舍去。
  - 该参数的取值范围是 **[0, 1]**，表示一个百分比，比如 **0.3** 表示 **30%**，那么支持度小于 **30%** 的项集将被舍去。
  - 该参数的默认值为 **0.5**，常见的取值有 **0.5**，**0.1**，**0.05**。
- **min_confidence**：表示最小可信度。
  - 该参数的取值范围也是 **[0, 1]**。
  - 该参数的默认值为 **0.5**，常见的取值有 **1.0**，**0.9**，**0.8**。

使用 apriori 函数

首先，将表格中的购物清单转化成 **Python** 列表，如下：

```
data = [
    ('牛奶', '面包'),
    ('牛奶', '面包', '火腿'),
    ('面包', '火腿', '可乐'),
    ('火腿', '可乐', '方便面'),
    ('面包', '火腿', '可乐', '方便面')
]
```

挖掘频繁项集和频繁规则：

```
itemsets, rules = apriori(data, min_support=0.5,  min_confidence=1)
```

查看频繁项集和频繁规则：

```
>>> itemsets # 频繁项集
{1: { # 只有一个元素的项集
    ('面包',): 4, # 4 表示记录数
    ('火腿',): 4,
    ('可乐',): 3
```

```
    },
  2: { # 有两个元素的项集
    ('火腿', '面包'): 3,
    ('可乐', '火腿'): 3
    }
}
>>> rules # 频繁规则
[{可乐} -> {火腿}]
```

6，总结

本篇实验报告中主要介绍了什么是关联分析，关联分析中三个重要的概念，以及 **Apriori** 算法。**Apriori** 算法用于加快关联分析的速度，但它也需要多次扫描数据集。其实除了 **Apriori** 算法，还有其它算法也可以加快寻找频繁项集的速度。